Teoría de Transporte Óptimo

Práctica 13: Transporte entrópico y el algoritmo de Sinkhorn

Los ejercicios son los de la sección de ejercicios del Capítulo 13 de las notas del curso, con la misma numeración; las referencias a teoremas, proposiciones y secciones remiten a las notas (https://github.com/jfbonder/transporte-optimo).

Cuaderno: *Transporte entrópico y Sinkhorn* (abrir en Colab).

Ejercicio 13.1 (Propiedades de la entropía relativa)**.** Sean $a \in \mathbb{R}^n$, $b \in \mathbb{R}^m$ con entradas positivas y $\pi \in \Pi(a,b)$.

(a) Probar que $\mathrm{KL}(\pi \,|\, a \otimes b) = \sum_{ij} \pi_{ij} \log \pi_{ij} - \sum_i a_i \log a_i - \sum_j b_j \log b_j$; es decir, sobre $\Pi(a,b)$ la entropía relativa difiere de la entropía negativa $\sum \pi_{ij} \log \pi_{ij}$ en una constante. Deducir que el regularizador de Peyré–Cuturi de la Observación 13.2.2 produce el mismo minimizador π^ε.

(b) (Desigualdad de Pinsker.) Probar que $\|\pi - a \otimes b\|_1^2 \le 2\,\mathrm{KL}(\pi \,|\, a \otimes b)$. *Sugerencia:* reducirlo al caso de dos puntos (agrupar según el signo de $\pi_{ij} - a_i b_j$ y usar la desigualdad de log-suma $\sum_k s_k \log \frac{s_k}{r_k} \ge \left(\sum_k s_k\right) \log \frac{\sum_k s_k}{\sum_k r_k}$, que es la convexidad conjunta de $(s,r) \mapsto s \log \frac{s}{r}$) y estudiar la función $t \mapsto t \log \frac{t}{p} + (1-t) \log \frac{1-t}{1-p} - 2(t-p)^2$.

(c) Deducir de (b) y de la Proposición 13.4.1 la velocidad $\|\pi^\varepsilon - a \otimes b\|_1 \le 2\sqrt{\|C\|_\infty / \varepsilon}$.

(d) Probar que la cota $\mathrm{KL}(\pi \,|\, a \otimes b) \le \log \frac{1}{\min_i a_i}$ usada en el Teorema 13.4.2 es óptima: para $a = b$ uniformes en n puntos y π una matriz de permutación dividida por n hay igualdad.

Ejercicio 13.2 (El valor entrópico como función de ε)**.**

(a) Probar que $\varepsilon \mapsto \mathrm{OT}_\varepsilon(a,b)$ es no decreciente y cóncava en $(0,\infty)$ (es un ínfimo de funciones afines de ε), y que

$$\frac{d}{d\varepsilon} \mathrm{OT}_\varepsilon(a,b) = \mathrm{KL}(\pi^\varepsilon \,|\, a \otimes b)$$

donde sea derivable.

(b) Deducir que $\varepsilon \mapsto \mathrm{KL}(\pi^\varepsilon \,|\, a \otimes b)$ es no creciente y que $\varepsilon \mapsto \langle C, \pi^\varepsilon \rangle$ es no decreciente: al aumentar la regularización el plan se vuelve más «desordenado» y más caro.

(c) Probar que $\lim_{\varepsilon \to \infty} \mathrm{OT}_\varepsilon(a,b) = \langle C, a \otimes b \rangle$ y que $\lim_{\varepsilon \to 0} \mathrm{OT}_\varepsilon(a,b) = \mathrm{OT}(a,b)$, y que ambas convergencias son monótonas.

Ejercicio 13.3 (El soft-min)**.** Con la notación de la Definición 13.2.3:

(a) Probar que $(\varphi + s)^{c,\varepsilon} = (\varphi)^{c,\varepsilon} - s$ para $s \in \mathbb{R}$, y que $\varphi \le \tilde{\varphi}$ implica $(\varphi)^{c,\varepsilon} \ge (\tilde{\varphi})^{c,\varepsilon}$.

(b) Probar que $\varphi \mapsto (\varphi)^{c,\varepsilon}_j$ es cóncava y de clase C^∞, y calcular su gradiente: es (menos) el vector de probabilidad $\left(a_i e^{(\varphi_i - c_{ij})/\varepsilon} / \sum_k a_k e^{(\varphi_k - c_{kj})/\varepsilon}\right)_i$, la j-ésima columna normalizada del plan. Comparar con la c-transformada $\varphi^c_j = \min_i \{c_{ij} - \varphi_i\}$, que no es diferenciable.

(c) Probar que $\varphi \mapsto (\varphi)^{c,\varepsilon}$ es 1-Lipschitz para la norma $\|\cdot\|_\infty$, y que para $\varepsilon \to \infty$, $(\varphi)^{c,\varepsilon}_j \to \sum_i a_i (c_{ij} - \varphi_i)$: el soft-min tiende al promedio.

Ejercicio 13.4 (Unicidad de los potenciales entrópicos)**.** Sean (φ, ψ) y (φ', ψ') dos pares tales que $a_i b_j e^{(\varphi_i + \psi_j - c_{ij})/\varepsilon}$ y $a_i b_j e^{(\varphi'_i + \psi'_j - c_{ij})/\varepsilon}$ son ambos planes de $\Pi(a,b)$.

(a) Probar que ambos planes coinciden (son el único minimizador π^ε), y deducir que $\varphi_i + \psi_j = \varphi'_i + \psi'_j$ para todo (i,j).

(b) Concluir que $(\varphi', \psi') = (\varphi + s, \psi - s)$ para algún $s \in \mathbb{R}$. Contrastar con el caso $\varepsilon = 0$ (Ejercicio 5.2), en el que los potenciales pueden no ser únicos: ¿qué propiedad del plan entrópico lo explica?

(c) Probar que si $a = b$ y C es simétrica, entonces $\varphi^\varepsilon = \psi^\varepsilon$ con la normalización adecuada, y que en ese caso una iteración de Sinkhorn puede escribirse con un solo potencial.

Ejercicio 13.5 (Los potenciales entrópicos convergen a potenciales de Kantorovich)**.** Completar los detalles de la Observación 13.4.3.

(a) Normalizando $\varphi_1^\varepsilon = 0$, probar que $(\varphi^\varepsilon, \psi^\varepsilon)$ está acotado uniformemente para $\varepsilon \in (0, 1]$. *Sugerencia:* $\psi^\varepsilon = (\varphi^\varepsilon)^{c,\varepsilon}$ y el Lema 13.2.4 dan $\|\psi^\varepsilon - (\varphi^\varepsilon)^c\|_\infty \le \varepsilon \log \frac{1}{\min a_i}$; usar que $\varphi^\varepsilon = (\psi^\varepsilon)^{\bar c,\varepsilon}$ tiene oscilación a lo sumo $\max_{i,i',j} |c_{ij} - c_{i'j}|$ (Paso 2 de la demostración del Teorema 13.3.2), de modo que, con $\varphi_1^\varepsilon = 0$, φ^ε y luego $(\varphi^\varepsilon)^c$ están acotadas independientemente de ε.

(b) Probar que todo punto límite (φ^0, ψ^0) satisface $\psi^0 = (\varphi^0)^c$, $\varphi^0 = (\psi^0)^{\bar c}$ y $\varphi_i^0 + \psi_j^0 = c_{ij}$ sobre el soporte de π^0, y concluir que es un par óptimo del problema dual de Kantorovich.

(c) ¿Converge toda la familia $(\varphi^\varepsilon, \psi^\varepsilon)$, o solo subsucesiones? Discutirlo en el ejemplo del Ejercicio 5.1, donde los potenciales de Kantorovich forman un segmento: ¿a qué punto del segmento converge el límite entrópico? (La respuesta es delicada; ver [1].)

Ejercicio 13.6 (Sinkhorn en un paso)**.**

(a) Probar que si C es de la forma $c_{ij} = f_i + g_j$ entonces $\pi^\varepsilon = a \otimes b$ para todo ε, y el algoritmo de Sinkhorn converge en una iteración.

(b) Recíprocamente, probar que si $\pi^\varepsilon = a \otimes b$ para algún $\varepsilon > 0$, entonces C es de la forma (a). Deducir que π^ε tiene rango uno si y solo si C es de la forma (a).

(c) Sea $n = m = 2$. Escribir explícitamente π^ε en función de a, b, C y ε (el problema se reduce a una ecuación escalar) y verificar a mano los límites $\varepsilon \to 0$ y $\varepsilon \to \infty$.

Ejercicio 13.7 (Perspectiva de una función convexa)**.** Sea $f\colon (0,\infty) \to \mathbb{R}$ convexa. Probar que su *perspectiva* $g(p, q) = q\, f(p/q)$ es convexa en $\{p > 0,\, q > 0\}$, y deducir que $(p, q) \mapsto p \log(p/q)$ es convexa en $\{p \ge 0,\, q > 0\}$ (con $0 \log 0 = 0$). Es la convexidad que usa la demostración de la Proposición 13.5.2.

Ejercicio 13.8 (Baricentros entrópicos)**.**

(a) Probar directamente que $a \mapsto \widetilde{\mathrm{OT}}_\varepsilon(a, b^k)$ es estrictamente convexa en Σ_n, sin usar la entropía $H(a)$: si π y π' son los planes óptimos para $a \ne a'$, el plan $\frac12(\pi + \pi')$ es admisible para $\frac12(a + a')$, y la convexidad estricta de $\pi \mapsto \sum \pi_{ij}(\log \pi_{ij} - 1)$ da una desigualdad estricta (¿por qué $\pi \ne \pi'$?). Deducir otra vez la unicidad del baricentro entrópico.

(b) Interpretar el paso 3 del algoritmo de la Sección 13.5 como una *proyección de Bregman*: dados los planes $\pi^1, \dots, \pi^N$ (con primeras marginales $m^k = \pi^k \mathbf{1}$ distintas), probar que el problema

$$\min\Big\{ \sum_k \lambda_k \, \widetilde{\mathrm{KL}}(\tilde\pi^k \,|\, \pi^k) : \ \tilde\pi^k \mathbf{1} = a \text{ para todo } k, \ a \in \mathbb{R}^n_{\ge 0} \Big\},$$

donde $\widetilde{\mathrm{KL}}(p \,|\, q) = \sum p \log \frac{p}{q} - p + q$, tiene solución $\tilde\pi^k = \mathrm{diag}(a/m^k)\, \pi^k$ con $a = \prod_k (m^k)^{\lambda_k}$ (media geométrica ponderada, sin normalizar), que es la actualización del algoritmo. Probar que si en cambio se usa la KL usual y se impone $a \in \Sigma_n$, se obtiene la versión normalizada $a \propto \prod_k (m^k)^{\lambda_k}$. ¿Por qué no aparece la media aritmética?

(c) En el ejemplo de no unicidad de la Observación 12.3.3 (μ_1 con átomos en $(\pm 1, 0)$, μ_2 con átomos en $(0, \pm 1)$, sobre una grilla que contenga los cuatro candidatos $(\pm\frac12, \pm\frac12)$), probar que el baricentro entrópico es único para todo $\varepsilon > 0$ y simétrico respecto de los dos ejes, y describir su límite cuando $\varepsilon \to 0$.

Ejercicio 13.9 (Derivadas del costo de transporte)**.**

(a) *Sin regularizar.* Escribamos $\mathrm{OT}_C(a, b)$ para indicar la dependencia en la matriz de costos. Probar que, para a, b fijos, $C \mapsto \mathrm{OT}_C(a, b)$ es cóncava y que, si π^0 es un plan óptimo para C, entonces $\mathrm{OT}_{C'}(a, b) \le \mathrm{OT}_C(a, b) + \langle C' - C, \pi^0 \rangle$ para toda C'. Probar que si el plan óptimo para C es único, la función es diferenciable en C con derivadas parciales π^0_{ij}. Para $n = m = 2$, $a = b = (\frac12, \frac12)$, mostrar que $\mathrm{OT}_C(a, b) = \frac12 \min\{c_{11} + c_{22},\, c_{12} + c_{21}\}$ y deducir que no es diferenciable en $C = 0$.

(b) *Respecto de los pesos.* Probar, sin usar la Proposición 13.5.2 y escribiendo $\mathrm{OT}_\varepsilon(\cdot, b)$ como supremo de funciones afines, que, para b fijo, $a \mapsto \mathrm{OT}_\varepsilon(a, b)$ es convexa en el conjunto de vectores de probabilidad con entradas positivas. Probar que si $h \in \mathbb{R}^n$ satisface $\sum_i h_i = 0$, entonces

$$\frac{d}{dt}\Big|_{t=0} \mathrm{OT}_\varepsilon(a + th, b) = \sum_{i=1}^{n} h_i \varphi_i^\varepsilon,$$

es decir, el potencial entrópico φ^ε es el gradiente de OT_ε respecto de a, salvo una constante (que no se ve en las direcciones con $\sum h_i = 0$). *Sugerencia:* el funcional dual $\mathcal{D}_\varepsilon$ de (13.2.2) es afín en a para (φ, ψ) fijos; evaluarlo en los potenciales de a y en los de $a + th$, como en el Paso 1 de la demostración de la Proposición 13.2.5, y usar que $\sum_j \pi_{ij}^\varepsilon = a_i$.

Ejercicio 13.10 (El sesgo entrópico)**.** Con la notación de la Observación 13.4.5, sea c un costo con $c(x, x) = 0$ y $c(x, y) > 0$ para $x \neq y$, y sea $\alpha = \sum_{i=1}^n a_i \delta_{x_i}$ con $n \geq 2$ puntos distintos y $a_i > 0$.

(a) Probar que $0 < \mathrm{OT}_\varepsilon(\alpha, \alpha) \leq \varepsilon H(a)$, donde $H(a) = -\sum_i a_i \log a_i$. *Sugerencia:* para la cota superior, comparar con el plan diagonal; para la inferior, usar que el plan entrópico tiene todas sus entradas positivas.

(b) Sean $\alpha = \frac{1}{2}(\delta_{-1} + \delta_1)$ y $\beta_t = \frac{1}{2}(\delta_{-t} + \delta_t)$ en $\mathbb{R}$, con $c(x, y) = |x - y|^2$. Usando la Proposición 13.2.5 (para la regla de la cadena basta la primera parte: las entradas de C dependen de t) y la simetría del problema, probar que $\frac{d}{dt}\mathrm{OT}_\varepsilon(\alpha, \beta_t) > 0$ en $t = 1$: el mínimo de $\beta \mapsto \mathrm{OT}_\varepsilon(\alpha, \beta)$ no se alcanza en $\beta = \alpha$, y achicar el soporte de β disminuye el costo.

(c) Probar que la divergencia de Sinkhorn S_ε no cambia si en su definición se reemplaza OT_ε por el costo $\widetilde{\mathrm{OT}}_\varepsilon$ con el regularizador de Peyré–Cuturi (Sección 13.5).

(d) Probar que $S_\varepsilon(\alpha, \beta) \to \mathrm{OT}(\alpha, \beta)$ cuando $\varepsilon \to 0$, y que cuando $\varepsilon \to \infty$

$$S_\varepsilon(\alpha, \beta) \to \sum_{i,j} a_i b_j \, c(x_i, y_j) - \frac{1}{2}\sum_{i,k} a_i a_k \, c(x_i, x_k) - \frac{1}{2}\sum_{j,l} b_j b_l \, c(y_j, y_l).$$

Ejercicios computacionales. Los ejercicios siguientes se resuelven con el cuaderno *Transporte entrópico y Sinkhorn* (véase el Apéndice E); los enunciados figuran también al final del cuaderno. Las referencias a secciones son a las del cuaderno.

Ejercicio 13.11 (Convergencia de valores)**.** Graficar $\varepsilon \mapsto \mathrm{OT}_\varepsilon(a, b) - \mathrm{OT}(a, b)$ en escala logarítmica en ambos ejes para el ejemplo de la Sección 1 del cuaderno y estimar el orden de convergencia. Usar la implementación en el dominio logarítmico (la `sinkhorn_log` de la Sección 2.2 del cuaderno, o `ot.sinkhorn(..., method='sinkhorn_log')`): con ε chico la versión en términos de (u, v) devuelve `nan`, como se ve en la Sección 2.3. Al elegir el rango de ε, tener en cuenta que para ε muy chico la diferencia $\mathrm{OT}_\varepsilon - \mathrm{OT}$ queda por debajo de la precisión con la que converge el algoritmo. ¿Es $O(\varepsilon)$, como garantiza el Teorema 13.4.2, o mejor? Comparar la constante observada con $\log(1/\min_i a_i)$.

Ejercicio 13.12 (Sinkhorn y la mejora de potenciales)**.** Implementar la mejora de potenciales $\varphi \mapsto \varphi^{c\bar{c}}$ de la Proposición 6.1.5, sin regularización, y compararla con la iteración de Sinkhorn para ε pequeño partiendo del mismo φ. ¿Converge la versión no regularizada? ¿Y la regularizada? Comparar con el Ejercicio 6.5.

Ejercicio 13.13 (Costo de cada iteración)**.** Medir el tiempo de una iteración de Sinkhorn en el dominio logarítmico (Sección 2.2 del cuaderno) para $n = m = 500, 1000, 2000, 4000$ y verificar el crecimiento $O(nm)$. Comparar con el tiempo del método exacto (`ot.emd`) para $n = m = 500, 1000, 2000$ —con $n = 4000$ la matriz de costos sola ocupa 128 MB y el simplex puede tardar varios minutos— y extrapolar: ¿a partir de qué n conviene el método entrópico? Prestar atención a que el tiempo de `ot.emd` depende también de los datos, y no solo de n.

Ejercicio 13.14 (Un baricentro con $\varepsilon \to 0$)**.** En el ejemplo de la Sección 5.1 del cuaderno, calcular el baricentro entrópico de la Proposición 13.5.2 para

$$\varepsilon \in \{0{,}5,\ 0{,}2,\ 0{,}1,\ 0{,}05,\ 0{,}02,\ 0{,}01,\ 0{,}005\}$$

y graficar la distancia W_2 entre el baricentro entrópico y el exacto en función de ε, en escala logarítmica en ambos ejes. ¿Cuántas iteraciones hacen falta en cada caso?

Ejercicio 13.15 (Unicidad del baricentro entrópico)**.** Verificar numéricamente que el baricentro entrópico del ejemplo de no unicidad de la Observación 12.3.3 (μ_1 con átomos en $(\pm 1, 0)$, μ_2 con átomos en $(0, \pm 1)$, sobre una grilla que contenga los cuatro candidatos) es *único* y simétrico: la entropía rompe la degeneración eligiendo la combinación más «repartida». Como en la Sección 5.2 del cuaderno, conviene aplicar el núcleo separable en lugar de la matriz K^ε completa: sobre una grilla producto el costo de cada iteración pasa de $O(N^4)$ a $O(N^3)$. Alternativamente, alcanza con una grilla 15×15 que contenga $(\pm 1, 0)$, $(0, \pm 1)$ y $(\pm\frac{1}{2}, \pm\frac{1}{2})$. Comparar con el Ejercicio 13.8.

Referencias

[1] Roberto Cominetti and Jaime San Martín. Asymptotic analysis of the exponential penalty trajectory in linear programming. *Mathematical Programming*, 67:169–187, 1994.